

Hands-On GNN Chapter 10

Predicting Links with Graph Neural Networks

A7610 그래프신경망특론 / 조남언

June 8, 2026

목차

- 1 링크 예측 문제 개관
- 2 Graph Autoencoder (GAE)
- 3 Variational Graph Autoencoder (VGAE)
- 4 SEAL: 서브그래프 분류로서의 링크 예측
- 5 정리 및 비교

Link Prediction이란?

- 그래프 $G = (V, E)$ 에서 **관측되지 않은 엣지** $(u, v) \notin E$ 가 실제로 존재할 가능성을 추정
- 입력: 노드 집합 V , 현재까지 관측된 엣지 E_{obs} , (선택) 노드 특징 X
- 출력: 임의의 노드 쌍에 대한 연결 점수 $s(u, v) \in [0, 1]$

대표 응용

- 소셜 네트워크의 친구 추천
- 추천 시스템(사용자-아이템 이분그래프)
- 단백질 상호작용 예측, 약물-표적 상호작용
- 지식 그래프 자동 완성

전통적 휴리스틱과 학습 기반의 차이

접근	점수 함수 $s(u, v)$
Common Neighbors	$ \Gamma(u) \cap \Gamma(v) $
Jaccard	$ \Gamma(u) \cap \Gamma(v) / \Gamma(u) \cup \Gamma(v) $
Adamic-Adar	$\sum_{w \in \Gamma(u) \cap \Gamma(v)} 1 / \log \Gamma(w) $
Katz, PageRank	경로 기반 / 랜덤워크 기반
GAE/VGAE	$\sigma(\mathbf{z}_u^\top \mathbf{z}_v)$, $\mathbf{z} = \text{GNN}(X, A)$
SEAL	두 노드의 enclosing subgraph를 통째로 분류

- 휴리스틱: 도메인마다 잘 통하는 지표가 다름 (정해진 가정 위에서만 작동)
- GNN 기반: 데이터로부터 적절한 표현/점수 함수를 학습

Chapter 10에서 다루는 두 가지 모델

- **VGAE** (Variational Graph Autoencoder, Kipf & Welling, 2016)
 - 노드 임베딩을 확률분포로 학습
 - 디코더는 단순 내적 — **전체 그래프 수준**에서 한 번에 학습
- **SEAL** (Zhang & Chen, 2018)
 - 각 후보 링크 주변의 *enclosing subgraph*를 추출
 - DRNL로 노드 라벨을 부여한 뒤 **서브그래프 분류** 문제로 풀이

한 줄 비교: VGAE는 한 그래프 = 한 예제, SEAL은 한 후보 링크 = 한 예제.

데이터 분할: RandomLinkSplit

- 노드 분류와 달리, 링크 예측은 엣지를 train/val/test로 나눔
- 음성 엣지(negative edge)를 무작위로 샘플링해 이진 분류 데이터 구성

```
from torch_geometric.transforms import RandomLinkSplit
transform = RandomLinkSplit(
    num_val=0.05, num_test=0.1,
    is_undirected=True, split_labels=True,
    add_negative_train_samples=False, # 학습은 매 epoch 새로 샘플링
)
```


- pos_edge_label_index: 양성(실제) 엣지
- neg_edge_label_index: 음성(없는) 엣지
- 평가 지표: **AUC, AP**

GAE의 아이디어

- 인코더-디코더 구조를 그래프에 그대로 이식
- 인코더: $\mathbf{Z} = \text{GCN}(\mathbf{X}, \mathbf{A}) \in \mathbb{R}^{N \times d}$
- 디코더: 노드 임베딩의 내적 $\rightarrow$ 인접행렬 복원

$$\hat{\mathbf{A}} = \sigma(\mathbf{Z}\mathbf{Z}^\top)$$

$\hat{A}_{ij} = \sigma(\mathbf{z}_i^\top \mathbf{z}_j)$ 로 임의의 쌍을 한 번에 점수화. 유사한 노드끼리 임베딩 공간에서 가까워지도록 학습.



이진 교차엔트로피 형태:

$$\mathcal{L}_{\text{recon}} = - \sum_{(u,v) \in E^+} \log \hat{A}_{uv} - \sum_{(u,v) \in E^-} \log(1 - \hat{A}_{uv})$$

- E^+ : 양성 엣지, E^- : 무작위 음성 엣지
- 클래스 불균형(양성 $\ll$ 음성) 때문에 양/음 같은 수로 샘플링하는 것이 일반적
- 단점: 임베딩이 결정적(deterministic) — 노드별 불확실성을 표현 못함

각 노드 i 의 잠재변수 $\mathbf{z}_i$ 가 가우시안을 따른다고 가정:

$$q(\mathbf{z}_i \mid X, A) = \mathcal{N}(\boldsymbol{\mu}_i, \text{diag}(\boldsymbol{\sigma}_i^2))$$

두 개의 GCN으로 평균과 로그분산을 동시에 출력:

$$\boldsymbol{\mu} = \text{GCN}_{\boldsymbol{\mu}}(X, A)$$

$$\log \boldsymbol{\sigma} = \text{GCN}_{\boldsymbol{\sigma}}(X, A)$$

재매개화(reparameterization): $\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\epsilon}, \boldsymbol{\epsilon} \sim \mathcal{N}(0, I)$

$$\mathcal{L}_{\text{VGAE}} = \underbrace{\mathcal{L}_{\text{recon}}}_{\text{엣지 복원}} + \frac{1}{N} \underbrace{\text{KL}[q(Z | X, A) \parallel p(Z)]}_{\text{사전분포로의 정규화}}$$

- 사전분포 $p(Z) = \mathcal{N}(0, I)$
- KL은 정규화 역할 — 임베딩이 너무 자유로워지지 않게 함
- $1/N$ 가중치는 노드 수에 비례한 KL을 노드당 평균으로 정규화하는 효과
- 디코더는 GAE와 동일: $\hat{A}_{uv} = \sigma(\mathbf{z}_u^\top \mathbf{z}_v)$

PyG의 VGAE 인코더 구현

```
from torch_geometric.nn import GCNConv, VGAE

class Encoder(torch.nn.Module):
    def __init__(self, dim_in, dim_out):
        super().__init__()
        self.conv1 = GCNConv(dim_in, 2 * dim_out)
        self.conv_mu = GCNConv(2 * dim_out, dim_out)
        self.conv_logstd = GCNConv(2 * dim_out, dim_out)

    def forward(self, x, edge_index):
        x = self.conv1(x, edge_index).relu()
        return (self.conv_mu(x, edge_index),
                self.conv_logstd(x, edge_index))

model = VGAE(Encoder(dataset.num_features, 16)).to(device)
```

- VGAE 래퍼가 reparameterization, recon_loss, kl_loss 제공

```
def train():
    model.train()
    optimizer.zero_grad()
    z = model.encode(train_data.x, train_data.edge_index)
    loss = model.recon_loss(z, train_data.pos_edge_label_index) \
        + (1 / train_data.num_nodes) * model.kl_loss()
    loss.backward(); optimizer.step()
    return float(loss)


@torch.no_grad()
def test(data):
    model.eval()
    z = model.encode(data.x, data.edge_index)
    return model.test(z, data.pos_edge_label_index,
                      data.neg_edge_label_index)
```

- recon_loss는 내부적으로 음성 엣지를 매 *epoch* 자동 샘플링
- test 결과: AUC, AP


Cora 데이터셋 결과

- Encoder: GCN(1433→32) → GCN(32→16)×2
- 300 epoch, Adam (lr=0.01)
- 책: Test AUC ≈ 0.88 , AP ≈ 0.90
- 본 실행(CPU, 시드=0): **AUC = 0.869, AP = 0.872**

$\hat{A}$ 의 블록 구조 → 같은 클래스 노드끼리 높은 점수가 매겨짐 (homophily 학습됨).




VGAE 임베딩 시각화 (t-SNE)



- 16차원 잠재공간 $\rightarrow$ t-SNE 2D 투영
- Cora의 7개 클래스가 무지도 학습만으로 어느 정도 군집화됨
- 링크 예측만 학습했는데 클래스 구조가 자연스럽게 드러남 — homophily 그래프에서 링크와 클래스는 강하게 결합
- 단점도 같은 그림에서: 일부 클래스 (0, 3)는 임베딩이 흐트러져 있음


SEAL의 출발점



(Labonne, 2023)

- 핵심 통찰: 링크의 존재 여부는 두 노드 주변의 작은 구조에 의해 강하게 결정된다.
- 휴리스틱(CN, Adamic-Adar, Katz)들이 모두 **enclosing subgraph**의 함수
- 링크 예측을 이진 그래프 분류로 환원: 입력 = 후보 (u, v) 주변 k -hop, 출력 = 링크 1/0


k -hop 이웃 개념



- k -hop 이웃: 중심 노드로부터 최대 k 개의 엣지로 도달 가능한 노드 집합
- SEAL은 두 타겟 노드의 k -hop 이웃 합집합을 enclosing subgraph로 사용
- $k = 2$ 가 표준 — 너무 크면 비용 폭발, 너무 작으면 정보 부족

Enclosing Subgraph 추출

- 후보 노드 쌍 (u, v) 에 대해 두 노드의 **k -hop 이웃** 합집합으로 서브그래프 구성
- PyG의 `k_hop_subgraph({u,v}, k=2, ..., relabel_nodes=True)`



- 타겟 링크 (u, v) 자체는 서브그래프에서 제거 (정답을 보고 학습하면 안 됨)
- 학습/평가는 추출된 서브그래프 전체의 구조와 노드 정보로 결정

타깃 엣지 제거 코드

```
sub_nodes, sub_edge_index, mapping, _ = k_hop_subgraph(
    [src, dst], 2, dataset.edge_index, relabel_nodes=True)
src, dst = mapping.tolist()

# Remove target link from the subgraph
mask1 = (sub_edge_index[0] != src) | (sub_edge_index[1] != dst)
mask2 = (sub_edge_index[0] != dst) | (sub_edge_index[1] != src)
sub_edge_index = sub_edge_index[:, mask1 & mask2]
```

- 양방향 모두 제거 (is_undirected=True 가정)
- 양성/음성 쌍 모두 동일한 절차로 처리해야 데이터 분포가 일치

DRNL: Double-Radius Node Labeling

타깃 두 노드까지의 거리로 각 노드에 라벨을 부여:

- $d_x = d(x, u)$, $d_y = d(x, v)$
- 평균 $d = (d_x + d_y)/2$, 모듈로 $r = (d_x + d_y) \bmod 2$


$$z(x) = 1 + \min(d_x, d_y) + d \cdot (d + r - 1)$$

타깃 노드 두 개는 라벨 1 고정, 도달 불가 노드는 0. 왜 이렇게?

- GNN은 노드 자체에 누가 타깃인지 모름 — 라벨로 명시적으로 알려줘야 함
- 두 거리를 따로 쓰지 않고 하나의 정수로 인코딩 → one-hot 임베딩이 깔끔
- 거리 정보로 휴리스틱(CN, AA, ...)의 표현력을 포함

DRNL 라벨링 예시 (실제 Cora 서브그래프)

DRNL labels on a Cora enclosing subgraph ($k=2$, $N=9$)
red dashed = target link removed during training



SEAL Cora 실행 결과 (본 실행)

- 30 epoch, Adam ($\text{lr}=10^{-4}$), BCEWithLogitsLoss
- 책 결과: $\text{AUC} \approx 0.89$, $\text{AP} \approx 0.90$
- 본 실행(CPU, 시드=0): **$\text{AUC} = 0.786$, $\text{AP} = 0.802$**

차이 원인 추정

- Epoch 수가 30회로 짧음 — DGCNN은 더 긴 학습에서 안정화됨
- BCEWithLogitsLoss를 sigmoid 출력에 사용 (책 코드의 알려진 이슈) — 학습 신호가 약함
- 음성 샘플링 매번 무작위라 시드 영향

DRNL 라벨 계산 (책 코드 발췌)

```
# d_src : 노드 -> src 거리 (를dst 그래프에서 잠시 제외하고 계산)
# d_dst : 노드 -> dst 거리 (를src 잠시 제외하고 계산)
dist = d_src + d_dst
z = 1 + torch.min(d_src, d_dst) \
      + (dist // 2) * (dist // 2 + (dist % 2) - 1)
z[src], z[dst] = 1., 1.
z[torch.isnan(z)] = 0.

node_labels = F.one_hot(z.to(torch.long), num_classes=200).to(torch.float)
node_emb = node_features # 선택() 원본 노드 feature 결합
node_x = torch.cat([node_emb, node_labels], dim=1)
data = Data(x=node_x, z=z, edge_index=sub_edge_index, y=y)
```

- `shortest_path(..., indices=src)`로 거리 계산
- `dst`를 빼고 `d_src`를, `src`를 빼고 `d_dst`를 — 경로 누설 방지

DGCNN: SEAL의 분류기

4-layer GCN $\rightarrow$ **SortPooling** $\rightarrow$ 1D CNN $\rightarrow$ Dense

- **GCN layers**: $32 \rightarrow 32 \rightarrow 32 \rightarrow 1$ 채널, $\tanh$ 활성화, 모두 *concat*
- **SortPooling**: 마지막 채널 기준으로 상위 $k = 30$ 노드만 정렬해 고정 길이로
- **Conv1D**: 정렬된 시퀀스를 1D 합성곱으로 처리 $\rightarrow$ 텍스트 분류 형태
- **Dense $\rightarrow$ Sigmoid**: 링크 존재 확률

서브그래프 크기가 매번 달라도 고정 차원 표현을 얻는 것이 SortPooling의 역할.

DGCNN 코드 (요지)

```
class DGCNN(torch.nn.Module):
    def __init__(self, dim_in, k=30):
        super().__init__()
        self.gcn1 = GCNConv(dim_in, 32)
        self.gcn2 = GCNConv(32, 32)
        self.gcn3 = GCNConv(32, 32)
        self.gcn4 = GCNConv(32, 1)
        self.global_pool = aggr.SortAggregation(k=k)
        self.conv1 = Conv1d(1, 16, kernel_size=97, stride=97)
        self.conv2 = Conv1d(16, 32, kernel_size=5, stride=1)
        self.maxpool = MaxPool1d(2, 2)
        self.linear1 = Linear(352, 128); self.dropout = Dropout(0.5)
        self.linear2 = Linear(128, 1)
```

- GCN 출력을 *layer-wise concat* 한 뒤 SortPool로 $k = 30$ 개 노드 선택

SEAL의 장점

- 표현력이 강함 — DRNL이 거리/구조 정보를 명시적으로 인코딩, 휴리스틱들을 일반화
- 인덕티브(inductive): 학습된 모델로 새 그래프에서도 추론 가능

SEAL의 단점

- 후보 링크 하나당 서브그래프 추출 + DRNL 전처리가 필요해 비용이 큼
- VGAE는 한 번의 *encode* 후 모든 쌍에 대해 점수를 즉시 계산 가능
- 대규모 그래프(수억 노드)에선 사실상 적용 불가

VGAE vs SEAL 한눈에 보기

	VGAE	SEAL
관점	그래프 전체 임베딩	후보 링크별 서브그래프 분류
입력 단위	그래프 1개	후보 링크 1개
디코더	내적 $\sigma(z_u^\top z_v)$	DGCNN (GCN+SortPool+Conv1D)
노드 라벨	원본 feature만	원본 feature + DRNL one-hot
학습 비용	작음	큼 (서브그래프 전처리)
추론 비용	매우 작음 ($O(d)/\text{쌍}$)	큼 (쌍마다 서브그래프)
표현력	대칭/저차원 한계	휴리스틱 일반화, 풍부

핵심 메시지

- 링크 예측은 쌍에 대한 이진 분류 — 데이터 분할도 엣지 단위로
- GAE/VGAE: 노드 임베딩 + 내적 디코더, **확장성**이 강점
- SEAL: 서브그래프 분류로 환원, **표현력**이 강점
- DRNL은 GNN이 “타깃이 누구인지”를 알게 해주는 명시적 라벨 트릭

다음 장 예고 (Chapter 11): 그래프 생성 모델

질문 / 토론

- VGAE의 KL 항을 $1/N$ 로 나누는 이유?
- SEAL에서 enclosing subgraph의 반경 k 를 키우면?
- 산업 환경(수억 노드)에서 SEAL이 적용 가능할까?